

Ôn tập — bản dễ

Phân tích dữ liệu thông minh

Mỗi phần chỉ có ba thứ: **nó là gì**, **công thức**, **một ví dụ**.
Cần chi tiết hơn thì xem bản đầy đủ `on-tap.tex`.

Mục lục

1	Mô tả dữ liệu	2
2	Khoảng tin cậy	2
3	Kiểm định giả thuyết	3
4	Mô hình đồ thị	4
5	Phân tích nhân quả	5
6	Hồi quy tuyến tính	6
7	Hồi quy đa biến và logistic	7
8	Monte Carlo	7
9	Bảng tra	8

1 Mô tả dữ liệu

Nó là gì

Tóm tắt một đồng số thành vài con số dễ nói.

- **Trung bình** — điểm cân bằng.
- **Trung vị** — số đứng giữa khi sắp thứ tự.
- **Độ lệch chuẩn** — dữ liệu tản ra bao xa quanh trung bình.

Công thức

$$\bar{x} = \frac{\text{tổng}}{n} \quad s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1} \quad s = \sqrt{s^2}$$

Nhớ: mẫu số là $n - 1$, không phải n .

Ví dụ

Dữ liệu: 2, 4, 4, 5, 7, 8. Trung bình = $30/6 = 5$.

Lấy từng số trừ 5 rồi bình phương: $9 + 1 + 1 + 0 + 4 + 9 = 24$.

$$s^2 = \frac{24}{6 - 1} = 4,8 \quad s = \sqrt{4,8} = 2,19$$

Hai hệ số tương quan

Do hai biến có đi cùng nhau không. Cả hai đều nằm trong khoảng từ -1 đến 1 .

	Pearson	Spearman
Hỏi gì	hai biến có nằm trên một đường thẳng không	có cùng tăng cùng giảm không
Dùng khi	dữ liệu là số	dữ liệu là số hoặc là thứ hạng

Gần $+1$ là cùng chiều mạnh, gần -1 là ngược chiều mạnh, gần 0 là không liên quan.

Nhớ: trung bình bị số quá lớn hoặc quá nhỏ kéo đi, trung vị thì không. Dữ liệu có số bất thường (thu nhập, giá nhà) thì báo cáo trung vị.

2 Khoảng tin cậy

Nó là gì

Ta chỉ đo được một mẫu, không đo được cả nước. Khoảng tin cậy là câu trả lời kèm biên độ sai: “*khoảng chừng từ đây tới đây*”.

Công thức

$$\text{con số đo được} \pm z^* \times SE$$

Với tỉ lệ phần trăm:

$$SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \quad z^* = 1,96 \text{ cho độ tin cậy 95\%}$$

Ví dụ

Hỏi 850 người, có 67% đồng ý. Vậy $\hat{p} = 0,67$ và $n = 850$.

$$SE = \sqrt{\frac{0,67 \times 0,33}{850}} = 0,0161$$
$$0,67 \pm 1,96 \times 0,0161 = 0,67 \pm 0,032 = (0,64; 0,70)$$

Đọc: “*tin cậy 95% rằng tỉ lệ thật nằm trong khoảng 64% đến 70%*”.

Nhớ: mẫu càng lớn thì khoảng càng hẹp. Muốn khoảng hẹp đi một nửa thì phải lấy mẫu lớn gấp bốn.

3 Kiểm định giả thuyết

Nó là gì

Có một tuyên bố. Ta có dữ liệu. Hỏi: dữ liệu có đủ mạnh để bác bỏ tuyên bố đó không, hay chênh lệch chỉ là may rủi.

Bốn bước

1. Viết H_0 (tuyên bố cần thử) và H_a (điều ta nghi ngờ).
2. Tính thống kê kiểm định (z hoặc t).
3. So với ngưỡng, hoặc tính p-value.
4. **p-value nhỏ hơn α thì bác bỏ H_0 .**

Ba công thức đủ dùng cho phần lớn bài

Đề cho gì	Dùng công thức
Một trung bình, có s	$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$ với $df = n - 1$
Một tỉ lệ	$z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$
Hai trung bình, mẫu lớn	$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$

Ngưỡng nào

Đề hỏi	Kiểu	Ngưỡng khi $\alpha = 0,05$
“có khác không”	hai phía	$ z > 1,96$
“có tăng không”	một phía	$z > 1,645$
“có giảm không”	một phía	$z < -1,645$

Ví dụ

Giám đốc nói lương trung bình là 380. Lấy mẫu $n = 36$ người thấy $\bar{x} = 350$ và $s = 40$. Kiểm ở $\alpha = 0,05$.

H_0 : lương = 380. H_a : lương $\neq$ 380 (hai phía).

$$t = \frac{350 - 380}{40/\sqrt{36}} = \frac{-30}{6,667} = -4,50$$

Ngưỡng là 2,030. Vì $4,50 > 2,030$ nên **bác bỏ** H_0 — lương thật sự thấp hơn 380.

Nhớ: không bác bỏ được thì viết “*chưa đủ bằng chứng*”, đừng viết “*chấp nhận H_0* ”.

4 Mô hình đồ thị

Nó là gì

Vẽ mũi tên giữa các biến để biết cái nào ảnh hưởng cái nào, rồi từ đó biết khi phân tích thì *phải giữ cố định biến nào*.

Ba hình cần thuộc

Hình	Tên	Có kiểm soát không
$X \leftarrow Z \rightarrow Y$	gây nhiễu	CÓ . Không kiểm soát thì kết quả sai.
$X \rightarrow Z \rightarrow Y$	trung gian	KHÔNG . Kiểm soát là xoá mất cái cần đo.
$X \rightarrow Z \leftarrow Y$	hội tụ	KHÔNG . Kiểm soát là tự tạo ra liên hệ giả.

Cách nhận ra: nhìn chiều mũi tên ở biến giữa. Hai mũi tên *đâm vào* nó thì đó là hội tụ.

Ví dụ

Muốn biết *học thêm* có làm *điểm* cao lên không. Nhưng *gia đình khá giả* vừa làm trẻ dễ đi học thêm hơn, vừa làm điểm cao hơn.

$$\text{học thêm} \leftarrow \text{gia đình khá giả} \rightarrow \text{điểm}$$

Đây là **gây nhiễu**. Không giữ cố định mức khá giả thì ta sẽ tưởng học thêm hiệu quả hơn thực tế.

Nhớ: chỉ kiểm soát biến *gây nhiễu*. Nhét hết mọi biến vào mô hình cho chắc là sai.

5 Phân tích nhân quả

Nó là gì

Phân biệt *đi cùng nhau* với *gây ra*.

Ý chính

Với mỗi người ta chỉ thấy được *một* kết cục: hoặc là có uống thuốc, hoặc là không. Cái còn lại vĩnh viễn không quan sát được. Nên không đo được tác động lên từng cá nhân, chỉ đo được **trung bình cả nhóm**:

$$ATE = \text{trung bình nhóm có} - \text{trung bình nhóm không}$$

Nhưng phép trừ này **chỉ đúng khi hai nhóm được chia ngẫu nhiên**. Chia ngẫu nhiên thì hai nhóm giống nhau ở mọi mặt khác, nên chênh lệch còn lại đúng là do can thiệp.

Ví dụ ngược đời

Người tập gym khoẻ hơn người không tập. Có phải gym làm khoẻ không?

Chưa chắc — người vốn đã khoẻ mới hay đi gym. Hai nhóm khác nhau ngay từ đầu, nên phần chênh lệch không hoàn toàn là công của gym.

Nghịch lý Simpson

Cách chữa A tốt hơn B ở cả nhóm sỏi nhỏ (93% so với 87%) lẫn nhóm sỏi lớn (73% so với 69%). Nhưng gộp chung lại thì A chỉ được 78% còn B được 83% — B thắng.

Lý do: bác sĩ dành cách A cho ca nặng. Kích thước sỏi là **biến gây nhiễu**.

Nhớ: gặp trường hợp này thì tin con số *theo từng nhóm*, đừng tin con số gộp.

6 Hồi quy tuyến tính

Nó là gì

Vẽ một đường thẳng đi xuyên qua đám điểm, để từ x đoán ra y .

Công thức

$$\hat{y} = b_0 + b_1x \quad b_1 = \frac{S_{xy}}{S_{xx}} \quad b_0 = \bar{y} - b_1\bar{x}$$

b_1 là **độ dốc**: x tăng 1 thì y đổi bấy nhiêu.

R^2 cho biết đường thẳng giải thích được bao nhiêu phần trăm biến động của y . $R^2 = 0,73$ nghĩa là 73%.

Ví dụ

x	1	2	3	4	5
y	2	4	5	4	9

Tính được $\bar{x} = 3$, $\bar{y} = 4,8$, $S_{xy} = 14$, $S_{xx} = 10$.

$$b_1 = \frac{14}{10} = 1,4 \quad b_0 = 4,8 - 1,4 \times 3 = 0,6$$

Vậy $\hat{y} = 0,6 + 1,4x$. Đọc: x tăng 1 thì y tăng khoảng 1,4.

Cách tự kiểm tra: thay $x = \bar{x} = 3$ vào phải ra đúng $\bar{y} = 4,8$. Thử: $0,6 + 1,4 \times 3 = 4,8$. Đúng.

Nhớ: dữ liệu quan sát thì viết “*đi kèm*”, đừng viết “*làm cho*”.

7 Hồi quy đa biến và logistic

Đa biến — nhiều x cùng lúc

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots$$

Đọc b_1 : x_1 tăng 1 đơn vị thì y đổi bấy nhiêu, **khi các biến còn lại giữ nguyên**. Cụm in đậm bắt buộc phải viết.

Logistic — khi y chỉ có hai giá trị

Dùng khi y là có/không, đậu/rớt, sống/chết. Không dùng đường thẳng được vì đường thẳng có thể cho ra xác suất âm hoặc lớn hơn 1.

Ba bước, làm đúng thứ tự:

1. Thay số vào để được **logit**.
2. $\text{odds} = e^{\text{logit}}$.
3. $\text{xác suất} = \frac{\text{odds}}{1 + \text{odds}}$.

Ví dụ

Cho $\text{logit} = 1,8185 - 0,0665 \times \text{tuổi}$. Tính xác suất sống sót của người 25 tuổi.

1. $\text{logit} = 1,8185 - 0,0665 \times 25 = 0,156$
2. $\text{odds} = e^{0,156} = 1,169$
3. $\text{xác suất} = \frac{1,169}{1 + 1,169} = 0,539$

Vậy khoảng 54%.

Nhớ: e^β là *tỉ số odds*, không phải tỉ số xác suất. Hệ số $\beta = 0$ nghĩa là không ảnh hưởng, vì $e^0 = 1$.

8 Monte Carlo

Nó là gì

Bài toán khó tính bằng công thức thì *bóc số ngẫu nhiên rất nhiều lần rồi đếm*.

Ví dụ kinh điển — tính số π

Vẽ một hình vuông và đường tròn nội tiếp. Ném ngẫu nhiên n điểm vào hình vuông, đếm được k điểm rơi vào trong tròn. Khi đó:

$$\pi \approx 4 \times \frac{k}{n}$$

Càng ném nhiều càng chính xác.

Sai số

$$SE = \frac{\sigma}{\sqrt{n}}$$

Nhớ: muốn sai số giảm một nửa thì phải chạy **gấp bốn lần** số vòng.

Bootstrap

Có đúng một mẫu gồm n món, muốn biết kết quả của mình chắc chắn tới đâu:

1. Bốc **có hoàn lại** đúng n món (bốc xong bỏ lại vào, nên có món trùng hai lần, có món không trùng lần nào).
2. Tính lại con số cần tính.
3. Lặp vài nghìn lần.
4. Độ tản của mấy nghìn kết quả đó chính là sai số.

9 Bảng tra

Độ tin cậy	90%	95%	98%	99%
z^* hai phía	1,645	1,96	2,33	2,576
z một phía	1,282	1,645	2,054	2,326

Thuộc ba số **1,96** — **1,645** — **2,576** là gỡ được phần lớn bài.

Năm câu đừng viết sai

1. p-value *không* phải xác suất H_0 đúng.
2. Viết “*chưa đủ bằng chứng để bác bỏ*”, đừng viết “*chấp nhận H_0* ”.
3. Phương sai chia $n - 1$; hồi quy dùng $df = n - 2$.
4. Dữ liệu quan sát thì viết “*đi kèm*”, đừng viết “*làm cho*”.
5. Chỉ kiểm soát biến *gây nhiễu*, không kiểm soát biến trung gian và hội tụ.